AI / ML ENGINEERING BOOTCAMP | HOMEWORK 10

Machine Learning-ə Giriş və ML Workflow

REMINDERS • FUNCTION EXAMPLES • PRACTICAL TASKS

Part 1 — Reminders

Tapşırıqlara başlamazdan əvvəl dərsdə öyrəndiyimiz əsas anlayışları xatırlayaq.

1. Machine Learning nədir?

Artificial Intelligence (AI) kompüterlərin insan intellekti tələb edən tapşırıqları yerinə yetirməsinə yönəlmiş geniş sahədir.

Machine Learning (ML) kompüterin bütün qaydaları programmer tərəfindən ayrıca yazılmadan, data üzərindəki əlaqələri öyrənərək prediction etməsinə imkan verən AI yanaşmasıdır.

Deep Learning (DL) Machine Learning-in neural network-lara əsaslanan alt sahəsidir.

Machine Learning-də əsas məqsəd sadəcə mövcud datanı analiz etmək deyil, həmin datadan öyrənərək yeni məlumatlar üçün prediction etməkdir.

2. Machine Learning növləri

Supervised Learning

Model training zamanı həm input məlumatları, həm də düzgün cavabları görür.

Məsələn:

- Evin sahəsinə və otaq sayına əsasən qiymətini təxmin etmək.
- Müştərinin xidmətdən ayrılıb-ayrılmayacağını təxmin etmək.

Unsupervised Learning

Modelə əvvəlcədən düzgün cavablar təqdim edilmir. Model datadakı oxşarlıqları və strukturları aşkar etməyə çalışır.

Məsələn, müştəriləri davranışlarına əsasən qruplaşdırmaq.

3. Regression və Classification

Regression: Model rəqəmsal dəyər təxmin edir.

Nümunə: Evin qiyməti 175000 AZN.

Classification: Model class və ya category təxmin edir.

Nümunə: Email spamdırmı yoxsa deyil?

4. Dataset, Features və Target

Dataset məlumatların saxlandığı strukturlaşdırılmış toplusudur.

Features (X) modelin prediction üçün istifadə etdiyi input məlumatlarıdır.

Target (y) modeldən təxmin etməsini istədiyimiz nəticədir.

Məsələn, ev-qiyməti-prediction sistemində sahə və otaq sayı features, qiymət isə target ola bilər.

Vacib: Targeti səhvən features daxilinə əlavə etmək olmaz. Model prediction zamanı bilmədiyi cavabı training zamanı input kimi almamalıdır.

5. Training və Testing

Modeli qiymətləndirmək üçün dataset adətən iki hissəyə ayrılır.

Training set: Modelin öyrənməsi üçün istifadə olunur.

Test set: Modelin əvvəllər görmədiyi məlumatlarda necə işlədiyini yoxlamaq üçün istifadə olunur.

Dərsdə istifadə etdiyimiz **train_test_split()** funksiyası bu bölünməni həyata keçirir.

- **test_size=0.25** — datanın 25%-i test üçün ayrılır.
- **random_state=42** — eyni random bölünməni təkrar əldə etməyə kömək edir.

6. Python, Pandas və Scikit-learn funksiyaları

Aşağıdakı nümunələr sizə tapşırıq zamanı lazım olacaq function, method və propertyləri xatırlatmaq üçündür.

6.1. pd.read_csv() — CSV faylını oxumaq

CSV faylındakı məlumatları Pandas DataFrame şəklində oxuyur.

İSTİFADƏ

```
import pandas as pd

df = pd.read_csv("lesson10_homework_houses.csv")

print(df.head(2))
```

NƏTİCƏ

```
   area_m2  rooms  building_age  price_azn
0       57      1            22      93200
1       59      2            15     108500
```

İzah: pd.read_csv() fayldakı məlumatları oxuyur və **df** variable-ində DataFrame saxlayır. **head(2)** ilk iki row-u göstərir.

6.2. .shape — Dataset-in ölçüsünü yoxlamaq

İSTİFADƏ

```
print(df.shape)
```

NƏTİCƏ

```
(80, 4)
```

İzah: Birinci rəqəm row sayını, ikinci rəqəm column sayını göstərir.

Qeyd: .shape method deyil, property-dir. Buna görə sonunda **()** yazmırıq.

6.3. .info() — Dataset haqqında məlumat almaq

İSTİFADƏ

```
df.info()
```

NƏTİCƏ (ƏSAS HİSSƏ)

```
RangeIndex: 80 entries, 0 to 79
Data columns (total 4 columns):
 #   Column        Non-Null Count  Dtype
 0   area_m2       80 non-null     int64
 1   rooms         80 non-null     int64
 2   building_age  80 non-null     int64
 3   price_azn     80 non-null     int64
```

İzah: .info() DataFrame-dəki column-ları, data type-ları və missing olmayan dəyərlərin sayını göstərir. Burada **int64** həmin column-un integer dəyərlər saxladığını bildirir.

6.4. .describe() — Statistical summary

İSTİFADƏ

```
print(df["rooms"].describe())
```

NƏTİCƏ (YUVARLAQLAŞDIRILMIŞ)

```
count    80.00
mean      2.65
std       0.93
min       1.00
25%       2.00
50%       3.00
75%       3.00
max       4.00
```

İzah:

- **count** — neçə dəyər var.
- **mean** — orta qiymət.

- **std** — dəyərlərin orta ətrafında nə qədər dəyişdiyini göstərən standard deviation.
- **min** və **max** — ən kiçik və ən böyük dəyər.
- **25%**, **50%**, **75%** — datanın paylanmasını göstərən quartile dəyərləri.

Bütün numerical column-lar üçün **df.describe()** istifadə edə bilərsiniz.

6.5. .isna().sum() — Missing values yoxlamaq

İSTİFADƏ

```
print(df.isna().sum())
```

NƏTİCƏ

```
area_m2         0
rooms           0
building_age    0
price_azn       0
dtype: int64
```

İzah:

.isna() missing dəyərləri aşkar edir.

.sum() hər column-da neçə missing value olduğunu hesablayır.

Nəticədə **0** həmin column-da missing value olmadığını göstərir.

6.6. Column selection — Features və target seçmək

DataFrame-dən bir və ya bir neçə column seçə bilərik.

İSTİFADƏ

```
columns = df[["area_m2", "rooms"]]

print(columns.head(2))
```

NƏTİCƏ

```
   area_m2  rooms
0       57      1
1       59      2
```

İzah: İkiqat square bracket ilə bir neçə column seçdikdə nəticə DataFrame olur.

Tək column seçmək üçün:

İSTİFADƏ

```
prices = df["price_azn"]

print(prices.head(2))
```

NƏTİCƏ

```
0     93200
1    108500
Name: price_azn, dtype: int64
```

İzah: Bir column bu formada seçildikdə nəticə Pandas Series olur.

Bu fərq features və target variable-lərini hazırlayarkən vacibdir.

6.7. train_test_split() — Datanı bölmək

Dataset-i training və testing hissələrinə ayırır.

Aşağıdakı kiçik nümunədə yalnız dörd məlumatdan istifadə edək.

İSTİFADƏ

```
from sklearn.model_selection import train_test_split

values = [10, 20, 30, 40]
targets = [100, 200, 300, 400]

a, b, c, d = train_test_split(
    values,
    targets,
    test_size=0.25,
    random_state=42
)

print("Training:", a)
print("Testing:", b)
```

NƏTİCƏ

```
Training: [40, 10, 30]
Testing: [20]
```

İzah: Dörd nümunənin üçü training, biri testing üçün ayrıldı. **targets** dəyərləri də uyğun qaydada bölündü.

Funksiya ümumilikdə dörd nəticə qaytarır: training features, testing features, training target və testing target.

6.8. LinearRegression() və .fit() — Model yaratmaq və train etmək

LinearRegression() Regression model object-i yaradır.

.fit() isə modeli training məlumatları ilə train edir.

İSTİFADƏ

```
from sklearn.linear_model import LinearRegression

example_X = pd.DataFrame({
    "hours": [1, 2, 3, 4]
})

example_y = [10, 20, 30, 40]

model = LinearRegression()

model.fit(example_X, example_y)

print("Model training completed")
```

NƏTİCƏ

```
Model training completed
```

İzah:

LinearRegression() model yaradır.

fit() isə input məlumatları ilə düzgün cavablar arasındakı əlaqəni öyrənir.

Bu sadə nümunədə **hours** artdıqca target də artır.

fit() özü prediction nəticəsini çap etmir. Modelin training prosesini həyata keçirir.

6.9. .predict() — Prediction almaq

Training tamamlandıqdan sonra modeldən yeni dəyər üçün prediction ala bilərik.

Əvvəlki nümunədə yaratdığımız modeli istifadə edək.

İSTİFADƏ

```
new_data = pd.DataFrame({
    "hours": [5]
})

prediction = model.predict(new_data)

print(prediction)
```

NƏTİCƏ

```
[50.]
```

İzah: Model əvvəlki nümunələrdən **hours** ilə target arasındakı xətti əlaqəni öyrənib. Buna görə 5 üçün 50 prediction qaytarır.

predict() adətən NumPy array qaytarır.

Vacib: Training zamanı istifadə etdiyiniz features ilə prediction zamanı verdiyiniz features uyğun olmalıdır.

6.10. pd.DataFrame() — Yeni DataFrame yaratmaq

Yeni məlumatları table formasında saxlamaq üçün istifadə olunur.

İSTİFADƏ

```
new_houses = pd.DataFrame({
    "area_m2": [70, 90],
    "rooms": [2, 3]
})

print(new_houses)
```

NƏTİCƏ

```
   area_m2  rooms
0       70      2
1       90      3
```

İzah: Dictionary-də hər key column adı, hər list isə həmin column-un dəyərləridir.

Final Task zamanı modelə yeni evləri DataFrame şəklində göndərmək üçün bu yanaşma lazım olacaq.

6.11. .to_numpy() — Series-i NumPy array-ə çevirmək

İSTİFADƏ

```
prices = df["price_azn"].head(2)

print(prices.to_numpy())
```

NƏTİCƏ

```
[ 93200 108500]
```

İzah: Pandas Series daxilindəki dəyərləri NumPy array-ə çevirir.

Bu, real qiymətlərlə model prediction-larını yeni DataFrame daxilində müqayisə edərkən faydalıdır.

6.12. len() — Elementlərin sayını tapmaq

İSTİFADƏ

```
predictions = [120000, 145000, 180000]

print(len(predictions))
```

NƏTİCƏ

```
3
```

İzah: len() list və array kimi collection-larda elementlərin sayını qaytarır. Modelin neçə prediction verdiyini yoxlamaq üçün istifadə oluna bilər.

6.13. abs() — Absolute difference hesablamaq

İSTİFADƏ

```
real_price = 100000
predicted_price = 97000

error = abs(real_price - predicted_price)

print(error)
```

NƏTİCƏ

```
3000
```

İzah: abs() rəqəmin absolute value-sunu qaytarır. Nəticə mənfi olmur.

ML modelində real qiymətlə prediction arasındakı fərqin böyüklüyünü hesablamaq üçün istifadə edirik.

6.14. .mean() — Orta dəyəri hesablamaq

İSTİFADƏ

```
errors = pd.Series([1000, 2000, 3000])

average_error = errors.mean()

print(average_error)
```

NƏTİCƏ

```
2000.0
```

İzah: .mean() bütün dəyərlərin arithmetic mean-ni hesablayır.

Burada modelin üç prediction üzrə orta absolute error-u 2000-dir.

6.15. .round() və .astype(int) — Prediction-ları yuvarlaqlaşdırmaq

Regression prediction-ları decimal dəyərlər ola bilər.

İSTİFADƏ

```
prices = pd.Series([100000.4, 150000.7])

rounded_prices = prices.round().astype(int)

print(rounded_prices)
```

NƏTİCƏ

```
0    100000
1    150001
dtype: int64
```

İzah:

.round() dəyərləri yuvarlaqlaşdırır.

.astype(int) onları integer data type-a çevirir.

Prediction-ları oxunaqlı göstərmək üçün bu method-lardan istifadə edə bilərsiniz.

7. CSV faylını oxumaq

Dərsdə dataset-i Python dictionary vasitəsilə yaratmışdıq.

Real layihələrdə isə məlumatlar çox vaxt CSV faylında saxlanılır.

Bu homework-da da dataset-i CSV faylından oxuyacaqsınız.

Bunun üçün:

```
import pandas as pd

df = pd.read_csv("lesson10_homework_houses.csv")

print(df.head())
```

Burada:

pd.read_csv() CSV faylını oxuyur və Pandas DataFrame qaytarır.

df isə həmin DataFrame-i saxlayan variable-dır.

CSV faylını Python faylınızla eyni layihə qovluğunda saxlayın və VS Code terminalını həmin qovluqdan işlədin.

Part 2 — Dataset

Bu tapşırıq üçün sizə **lesson10_homework_houses.csv** adlı CSV faylı verilir.

Dataset-də **80 ev** haqqında məlumat var.

Column	Açıqlama
area_m2	Evin sahəsi, kvadratmetrlə
rooms	Otaq sayı
building_age	Binanın yaşı, il ilə
price_azn	Evin qiyməti, AZN ilə

Sizin məqsədiniz: Evin sahəsinə, otaq sayına və binanın yaşına əsasən qiymətini təxmin edən Machine Learning modeli yaratmaqdır.

Part 3 — Tasks

Task 1 — Dataset-i oxumaq və yoxlamaq

1. Pandas library-sini import edin.
2. CSV faylını oxuyun və **df** adlı DataFrame-də saxlayın.
3. İlk 5 row-u terminalda göstərin.
4. Dataset-in shape-ni göstərin.
5. **info()** və **describe()** vasitəsilə dataset-i yoxlayın.
6. Dataset-də missing values olub-olmadığını yoxlayın.

Task 2 — Features və Target

Dataset-dən features və target-i ayırın.

- Features **X** adlı variable-də saxlanmalıdır.
- Target **y** adlı variable-də saxlanmalıdır.
- Features olaraq **area_m2**, **rooms** və **building_age** istifadə edin.
- Target olaraq **price_azn** istifadə edin.

Sonra **X** və **y** variable-lərinin ilk 5 row-unu və shape-lərini göstərin.

Diqqət: price_azn features daxilində olmamalıdır.

Task 3 — Train/Test Split

train_test_split() istifadə edərək datanı bölün.

Şərtlər:

- 75% training data.
- 25% testing data.
- random_state=42.

Aşağıdakı variable-ləri yaradın:

- **X_train**
- **X_test**
- **y_train**
- **y_test**

Hər birinin shape-ni terminalda göstərin.

Task 4 — Model Training

Scikit-learn library-sindən **LinearRegression** istifadə edin.

1. Model object yaradın.
2. Modeli training datası ilə train edin.
3. Training zamanı uyğun features və target-dən istifadə edin.

Task 5 — Predictions

Artıq train etdiyiniz modeldən istifadə edin.

1. **X_test** üçün prediction alın.
2. Nəticələri **predictions** adlı variable-də saxlayın.
3. İlk 5 prediction-u terminalda göstərin.
4. Ümumilikdə neçə prediction aldığınızı yoxlayın.

Sonra real qiymətlərlə prediction-ları bir DataFrame daxilində yan-yana göstərin.

DataFrame-də bu column-lar olsun:

- **real_price_azn**
- **predicted_price_azn**