LESSON 07 • ASSIGNMENT

Homework 7
Pandas-a Giriş

AI/ML ENGINEERING BOOTCAMP / DATA ANALYSIS & PREPARATION

PART 01

Reminders (Xatırlatma)

Tapşırıqlara başlamazdan əvvəl dərsdə öyrəndiyimiz Pandas anlayışlarını və onların necə istifadə olunduğunu xatırlayaq.

1. Pandas nədir?

Pandas Python-da cədvəl formasında olan məlumatlarla işləmək üçün istifadə olunan library-dir.

Pandas vasitəsilə dataset-ləri oxuya, araşdıra, müəyyən sütunları və sətirləri seçə, şərtlərə uyğun məlumatları filter edə bilərik.

Pandas-ı import etmək üçün:

PYTHON

```
import pandas as pd
```

Burada `pd` Pandas üçün istifadə etdiyimiz qısa addır (nickname).

2. Series və DataFrame

Pandas-da iki əsas data structure var:

- **Series:** Birölçülü data structure-dır. Bir sütundakı məlumatları saxlamaq üçün istifadə olunur.
- **DataFrame:** İkiölçülü data structure-dır. Sətirlərdən (rows) və sütunlardan (columns) ibarət cədvəldir.

PYTHON

```
ages = pd.Series([24, 25, 23])

passengers = {
    "Name": ["Ayxan", "Tural", "Nigar"],
    "Age": [24, 25, 23]
}

df = pd.DataFrame(passengers)
```

`ages` Series, `df` isə DataFrame-dir.

3. CSV və Excel faylları

CSV (Comma-Separated Values) məlumatların sadə text formatında saxlandığı fayl növüdür. Dəyərlər vergüllə ayrılır.

Excel (.xlsx) isə məlumatları sheet-lər şəklində saxlayan cədvəl formatıdır.

Pandas bu faylları oxumağa imkan verir:

```python
df = pd.read_csv("titanic.csv")

# Excel faylı üçün:
df = pd.read_excel("data.xlsx")
```

`read_csv()` CSV faylını oxuyaraq DataFrame qaytarır. `read_excel()` isə Excel faylları üçün istifadə olunur.

4. Dataset haqqında ilkin məlumat

Yeni dataset ilə işləyəndə əvvəlcə onun strukturunu başa düşməliyik.

- `df.head()` — İlk 5 sətri göstərir. `head(10)` ilk 10 sətri göstərir.
- `df.tail()` — Son 5 sətri göstərir.
- `df.shape` — Dataset-in `(rows, columns)` ölçüsünü qaytarır.
- `df.columns` — Sütun adlarını göstərir.
- `df.info()` — Sütunlar, data type-lar və non-null(boş olmayan) dəyərlər haqqında məlumat verir.
- `df.describe()` — Numerical(Rəqəmsal) sütunların `count`, `mean`, `min`, `max` və digər statistik göstəricilərini hesablayır.

> **Qeyd:** `shape` və `columns` attribute(variable) olduğu üçün onlardan sonra `()` yazılmır. `head()`, `info()` və `describe()` isə method-dur.

5. Rows, Columns və Index

- **Row:** Cədvəldə bir sətirdir. Məsələn, bir sərnişinin bütün məlumatları.
- **Column:** Eyni kateqoriyaya aid məlumatların yerləşdiyi sütundur. Məsələn, `Age`.
- **Index:** Pandas-ın sətirləri tanımaq üçün istifadə etdiyi label-lardır.

Sətirləri seçmək üçün iki üsul öyrəndik:

`iloc` — Integer position əsasında seçim edir.

`loc` — Index label əsasında seçim edir.

```python
df.iloc[0]       # Birinci sətir
df.iloc[0:3]     # İlk 3 sətir

df.loc[0]        # Index label 0 olan sətir
df.loc[0, "Name"] # Həmin sətirdə Name dəyəri
```

Vacib fərq: `iloc[0:3]` position 3-ü daxil etmir. `loc[0:3]` isə uyğun label-lar mövcuddursa, 3-ü də daxil edir.

6. Column Selection

DataFrame-dən bizə lazım olan sütunları seçə bilərik.

PYTHON

```
df["Age"]
df[["Name", "Age"]]
```

- `df["Age"]` bir sütunu **Series** kimi qaytarır.
- `df[["Name", "Age"]]` iki sütunu **DataFrame** kimi qaytarır.

Hətta bir sütunu `df[["Age"]]` şəklində seçsək, nəticə DataFrame olacaq.

> **Qeyd:** Column name-lər case-sensitive-dir. `Age` və `age` eyni deyil. Yanlış sütun adı `KeyError` yarada bilər.

7. Filtering

Filtering dataset-dən yalnız müəyyən şərtə uyğun olan row-ları seçməkdir.

Məsələn:

PYTHON

```
df[df["Age"] >= 18]
```

Burada əvvəlcə hər row üçün `Age >= 18` şərti yoxlanılır. Şərtin nəticəsi `True` olan row-lar seçilir.

Mətn sütunlarında da filtering edə bilərik:

PYTHON

```
df[df["Sex"] == "female"]
```

Birdən çox şərt istifadə etmək üçün:

- `&` **(AND)** — Hər iki condition doğru olmalıdır.
- `|` **(OR)** — Condition-lardan ən azı biri doğru olmalıdır.

PYTHON

```
df[(df["Age"] >= 18) & (df["Pclass"] == 1)]

df[(df["Pclass"] == 1) | (df["Pclass"] == 2)]
```

Pandas Series-ləri üzərində bu cür filtering zamanı adi Python `and` / `or` əvəzinə `&` / `|` istifadə edirik.

> **Vacib:** Hər condition ayrıca mötərizə daxilində yazılmalıdır.

8. Filtering və Column Selection birlikdə

Əvvəl dataset-i filter edib, sonra yalnız lazım olan sütunları seçə bilərik.

PYTHON

```
adults = df[df["Age"] >= 18]

result = adults[["Name", "Age", "Sex"]]

print(result.head(10))
print(len(result))
```

Bu kod yaşı 18 və daha böyük olan sərnişinləri seçir, onların yalnız `Name`, `Age`, `Sex` sütunlarını göstərir və nəticədə neçə row olduğunu hesablayır.

> **Yadda saxlayın:** Pandas ilə işləyərkən əsas ardıcıllıq belədir:

Məlumatları Oxu → Məlumatları Araşdır → Sütunları Seç → Sətirləri Filtrlə → Nəticələri Yoxla

Bu addımlar real Data Analysis və Machine Learning layihələrində dataset ilə işləməyin əsasını təşkil edir.

PART 02

Tasks

Bütün task-lar üçün dərsdə istifadə etdiyimiz **Titanic dataset**-indən istifadə edin.

Hər task-da nəticələri `print()` vasitəsilə terminalda göstərin. Lazım olan məlumatları ayrıca variable-larda saxlamağa çalışın.

Task 1 — Dataset Investigation

Təsəvvür edin ki, sizə Titanic sərnişinləri haqqında yeni dataset göndərilib. İlk işiniz dataset-i araşdırmaq və onun strukturu haqqında məlumat əldə etməkdir.

Dataset URL:

https://raw.githubusercontent.com/pandas-dev/pandas/main/doc/data/titanic.csv

Dataset-i birbaşa URL-dən oxuyaraq DataFrame-ə çevirmək mümkündür:

PYTHON

```
import pandas as pd

url = "https://raw.githubusercontent.com/pandas-dev/pandas/main/doc/data/titanic.csv"

df = pd.read_csv(url)

print(df.head())
```

Burada `pd.read_csv(url)` CSV faylını internet üzərindən oxuyur və nəticəni DataFrame şəklində qaytarır.

Dataset-i lokal fayl kimi saxlamaq üçün:

PYTHON

```
df.to_csv("titanic.csv", index=False)
```

Bundan sonra dataset-i lokal fayldan da oxuya bilərsiniz:

PYTHON

```
df = pd.read_csv("titanic.csv")
```

Tapşırıqlar:

1. Dataset-i URL vasitəsilə oxuyun və `titanic.csv` adı ilə kompüterinizdə saxlayın.
2. Dataset-in ilk 7 və son 3 sətrini göstərin.
3. Dataset-də neçə row və neçə column olduğunu, həmçinin bütün column name-ləri göstərin.
4. `info()` və `describe()` istifadə edərək dataset-i araşdırın. `Age` sütununda neçə non-null value olduğunu tapın.
5. `iloc` istifadə edərək 5-ci, 6-cı və 7-ci position-lardakı sərnişinləri göstərin.

6. `loc` istifadə edərək index label-ı `10` olan sərnişinin yalnız `Name`, `Age` və `Fare` məlumatlarını göstərin.
7. Yalnız `Name`, `Age` və `Survived` sütunlarından ibarət yeni DataFrame yaradın və onun ilk 10 sətrini göstərin.

Task 2 — Passenger Filtering

Titanic sərnişinləri arasında müəyyən qrupları araşdırmaq istəyirik. Bunun üçün filtering və column selection istifadə edin.

Part A — Adult Passengers

1. Yaşı 18 və daha böyük olan, eyni zamanda 3-cü sinifdə (`Pclass == 3`) səyahət edən sərnişinləri tapın.
2. Nəticədən yalnız `Name`, `Age`, `Pclass` və `Fare` sütunlarını seçin.
3. İlk 10 sətri göstərin və ümumilikdə neçə sərnişin tapıldığını hesablayın.

Part B — Young Passengers

1. Yaşı 18-dən kiçik olan və 1-ci **və ya** 2-ci sinifdə səyahət edən sərnişinləri tapın.
2. Nəticədə yalnız `Name`, `Age`, `Pclass` və `Survived` sütunlarını göstərin.
3. İlk 10 sətri və ümumi sərnişin sayını göstərin.

> **Hint:** Bu task-da həm `&` (AND), həm də `|` (OR) operator-larından istifadə etməlisiniz. Condition-lar üçün mötərizələri unutmayın.

Final Task — Titanic Survival Report

Siz Titanic dataset-i üzərində kiçik bir analiz hazırlayırsınız.

Məqsədiniz 1-ci sinifdə səyahət etmiş, yaşı ən azı 18 olan sərnişinlər arasında **xilas olanlarla xilas olmayanları müqayisə etməkdir.**

Part A — Survived Passengers

1. `Pclass == 1`, `Age >= 18` və `Survived == 1` şərtlərinə uyğun sərnişinləri seçin.
2. Yalnız `Name`, `Age`, `Sex` və `Fare` sütunlarından ibarət yeni DataFrame yaradın.
3. İlk 10 sətri göstərin.
4. Bu qrupa neçə sərnişinin daxil olduğunu və onların average (ortalama) bilet qiymətini hesablayın.

Part B — Non-Survived Passengers

1. Eyni şərtləri istifadə edin, amma bu dəfə yalnız xilas olmayan (`Survived == 0`) sərnişinləri seçin.
2. Yenə yalnız `Name`, `Age`, `Sex` və `Fare` sütunlarını göstərin.
3. İlk 10 sətri göstərin.
4. Bu qrupa neçə sərnişinin daxil olduğunu və onların average bilet qiymətini hesablayın.

Part C — Final Report

Terminalda iki qrup üzrə nəticələri aydın şəkildə göstərin:

- Xilas olan sərnişinlərin sayı və average bilet qiyməti.
- Xilas olmayan sərnişinlərin sayı və average bilet qiyməti.

> **Hint:** Average bilet qiymətini hesablamaq üçün dərsdə gördüyümüz `.mean()` metodundan istifadə edə bilərsiniz.

Uğurlar!